



**MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS E
INTELIGENCIA ARTIFICIAL**

**Estudio del proceso de concesión de crédito y análisis
de sesgos**

CUNEF Universidad

Realizado por: Javier Gilsanz Muñoz

Dirigido por: Elisa Cabana Garcerán del Vall

Índice

1. Objetivos	3
2. Metodología.....	3
3. Resultados	6
4. Conclusiones	8

1. Objetivos

La digitalización ha transformado la manera en la que se toman decisiones para múltiples sectores, el financiero es uno de ellos, siendo además uno de los más impactados. Concretamente, ha evolucionado debido a la incorporación de modelos de Machine Learning. Estos modelos son capaces de analizar grandes volúmenes de datos con el objetivo de explicar y predecir la probabilidad de aceptar o no una concesión. Este sistema facilita y agiliza la evaluación tradicional.

Pero la digitalización trae consigo importantes desafíos. La aplicación de estos modelos automatizados puede reproducir sesgos e incluso amplificar los sesgos históricos usados en el entrenamiento. Los sesgos son distorsiones que afectan en este caso a las decisiones de concesión de un solicitante que no son completamente objetivas y no están basadas únicamente en datos.

El objetivo del proyecto de investigación consiste en analizar la posible existencia de sesgos, en modelos de concesión automatizada. Se pretende averiguar si un modelo puede alcanzar una capacidad predictiva alta, y al mismo tiempo, reproducir desigualdades entre colectivos. 'sexo', 'raza' y 'etnia' son las variables sensibles de interés para ello, seleccionados por su importancia en la literatura sobre *fairness*.

La idea central sostiene que un modelo no se puede medir únicamente a través de métricas de acierto. En problemas como este de concesiones de crédito, donde la decisión condiciona el acceso a la vivienda, patrimonio y movilidad socioeconómica, la capacidad predictiva debe de analizarse en paralelo con la equidad del sistema. A partir de esta premisa, se sigue el siguiente *pipeline*: técnicas de análisis exploratorio, regresión logística, regularización mediante LASSO, modelos clásicos de Machine Learning, una aproximación socioeconómica al contexto de los solicitantes, una red neuronal multicapa y herramientas de explicabilidad como SHAP.

El objetivo es comprobar si las decisiones automatizadas de crédito incorporan o reproducen sesgos, de qué forma lo hacen y qué evidencia empírica puede aportarse para sostener esa conclusión.

2. Metodología

El análisis comienza a partir de un *dataset* de un conjunto inicial de 4,3 millones de observaciones (filas), y 100 variables (columnas). Este tamaño permite trabajar bajo una base empírica amplia, pero también requiere más cuidado y atención a la hora de seleccionar y tratar las variables que serán la base del estudio.

El *análisis exploratorio inicial* (EDA), muestra la presencia de *outliers*, de variables nulos (NaN), codificaciones mixtas, categorías desbalanceadas, variables post-concesión sin relevancia para nuestro estudio entre otros problemas o ruido. Por ello y con el fin de hacer un estudio correcto y estable, se considera un paso esencial del TFM y no una tarea meramente instrumental.

A partir del estudio descriptivo de distribuciones, variables categóricas, variables numéricas, *missings*, *outliers* y correlaciones, se definió un nuevo conjunto de trabajo denominado ``df_model``. Esta nueva estructura se diseñó con dos objetivos complementarios.

En primer lugar, conservar las variables con interpretación económica y capacidad para la explicabilidad en la concesión de crédito. Por otro lado, se preservan dimensiones que permiten analizar posibles sesgos, como el perfil demográfico y el contexto territorial. La variable objetivo (*target*) se recodifica y se convierte en una variable binaria, donde *target* = 1 representa concesión y *target* = 0 denegación.

Durante esta fase se toman decisiones relevantes, como la eliminación de variables por presentar una combinación de valor informativo muy bajo y niveles extremos de *missings*. En otras variables se opta por recodificar la información para poder mantener su interpretación económica. También se presta atención a la diferencia entre *missings* aleatorios y un *missing* estructural, para evitar distorsiones en la lectura de ciertos atributos. En términos generales, el resultado fue un conjunto final mucho más robusto, donde cada variable mantenía una función clara dentro del análisis.

Una de las fortalezas del TFM es que no se apoyó en un único modelo ni en una única forma de evaluar el problema. *La estrategia seguida fue progresiva*. Primero se estudió la estructura del dato. Después, se introduce una regresión logística como punto de referencia del que se obtienen las primeras conclusiones, seguido de LASSO, regresión utilizada para seleccionar variables de manera automática. Posteriormente, se comparan modelos de Machine Learning, a través de validación cruzada, y se concluye que los modelos que se basan en algoritmos *boosting* tienen un mayor rendimiento por su capacidad para corregir errores a medida que avanza el entrenamiento. Por último, se incorpora una red neuronal multicapa de 4 capas como contraste de mayor flexibilidad. Como cuarta capa de la red, se añade una capa de explicabilidad mediante SHAP para interpretar el comportamiento del modelo neuronal y reforzar la defensa metodológica del trabajo. Esta secuencia no solo es lógica, sino que también interpretable y argumentable. La regresión logística aporta interpretabilidad, LASSO ayuda a priorizar variables, los modelos de Machine Learning permiten capturar relaciones más complejas (no lineales). La red neuronal comprueba si ese patrón se mantiene en una arquitectura distinta. Y SHAP permite cerrar el círculo mostrando qué variables son realmente relevantes en las decisiones del modelo.

La regresión logística permitió establecer una primera referencia sobre la relación entre las variables explicativas y la variable objetivo. Su principal valor dentro del TFM *no fue únicamente predictivo, sino interpretativo*. Gracias a este modelo pudo observarse que variables financieras como la ratio deuda-ingresos, el sistema de evaluación y la relación préstamo-valor ya concentraban una parte importante de la señal explicativa. Este primer resultado fue relevante porque adelantaba algo que se confirmaría posteriormente con otros modelos: la decisión del sistema parece apoyarse sobre todo en factores económicos y de *scoring*, pero esos factores están profundamente conectados con desigualdades previas del entorno social.

La utilización de LASSO reforzó esta idea. La regularización permitió identificar las variables con mayor peso y, al mismo tiempo, evaluar qué ocurría al entrenar modelos con y sin atributos sensibles. El hallazgo más importante fue que *la exclusión de `sexo`, `raza` y `etnia` apenas alteró la capacidad predictiva del modelo*. La diferencia en AUC entre la especificación base y la que incluía variables sensibles fue muy reducida, del orden de unas milésimas. Este resultado no se interpretó como una evidencia de ausencia de sesgo, sino como una señal de que el modelo es capaz de reconstruir indirectamente la información sensible mediante otras variables. En otras palabras, si quitar los atributos sensibles no cambia prácticamente el rendimiento, es porque el resto del conjunto de datos contiene señales suficientemente correlacionadas con ellos como para seguir diferenciando entre grupos.

Desde el punto de vista conceptual, este es uno de los puntos más fuertes del TFM. La investigación muestra que *la equidad no puede garantizarse simplemente mediante una estrategia de “ceguera” frente a variables sensibles*. La eliminación de esos atributos puede reducir el riesgo de un uso directo, pero no elimina el problema cuando existen proxies relacionados con el territorio, la renta, el scoring, la estructura del préstamo o el entorno económico del solicitante. Así, el análisis con LASSO no solo ayuda a seleccionar variables, sino que se convierte en una pieza central para entender la naturaleza del sesgo que puede estar presente en el sistema.

Una vez definido el conjunto de trabajo y contrastadas las primeras señales en modelos lineales, se desarrolló un *benchmark* de modelos de *machine learning*. El objetivo de esta fase fue doble. Por un lado, comparar el comportamiento predictivo de algoritmos con distinta capacidad de capturar no linealidades e interacciones. Por otro, comprobar si el patrón observado en la regresión logística se mantenía cuando el problema se abordaba con modelos más complejos.

3. Resultados

Los resultados mostraron que el problema de concesión de crédito es *altamente modelizable*. Entre los algoritmos probados, `HistGradientBoosting` destacó como el mejor modelo clásico en validación cruzada, con un `ROC-AUC` medio de 0,9260, un `PR-AUC` de 0,9471 y un `F1` de 0,8949. A continuación, aparecieron `XGBoost` y `GradientBoosting`, también con rendimientos altos, aunque algo inferiores. Esta evidencia es importante porque demuestra que la decisión de concesión incorpora regularidades estables y que dichas regularidades pueden ser capturadas con bastante precisión por algoritmos tabulares modernos.

Sin embargo, desde la lógica del TFM, el benchmark tiene un interés que va más allá del ranking de modelos. Su principal aportación es mostrar que un alto rendimiento agregado no resuelve el problema de la equidad. De hecho, cuanto más consistente es la señal predictiva, más importante es preguntarse qué relaciones está aprendiendo el algoritmo y si algunas de ellas están reflejando desigualdades ya existentes en la realidad social. Por ello, el benchmark funciona como una prueba de capacidad predictiva, pero también como una base para plantear con mayor fuerza la necesidad de incorporar *fairness* y explicabilidad.

La evaluación de *fairness* constituye el núcleo sustantivo del trabajo. En esta fase se analizaron métricas como `demographic parity`, `equal opportunity`, `average odds` y sus versiones absolutas, con el fin de medir en qué medida la tasa de predicción positiva, la capacidad de detectar la clase positiva y la combinación entre verdaderos y falsos positivos varían entre grupos sensibles. El objetivo no era encontrar una única métrica decisiva, sino construir una visión más robusta del problema desde distintos ángulos.

Los resultados muestran un patrón claro. *Las mayores brechas aparecen en `raza` y `etnia`, mientras que las diferencias asociadas a `sexo` son comparativamente menores*. Esto significa que el comportamiento desigual del modelo es más intenso cuando se observan grupos raciales o étnicos que cuando la comparación se centra exclusivamente en hombres y mujeres. Además, la comparación entre modelos con y sin variables sensibles no muestra una mejora consistente al incorporar dichos atributos. En algunos casos concretos puede aparecer una leve mejora en una métrica puntual, pero el patrón general es que la inclusión de variables sensibles no corrige de manera estable las brechas observadas y, en varias comparaciones, incluso las incrementa ligeramente.

Este resultado es crucial para la conclusión del TFM, porque permite descartar una interpretación ingenua del problema. El sesgo detectado no parece depender de una sola variable ni de una única decisión de modelización. Más bien, responde a una estructura de relaciones entre atributos que atraviesa los datos y reaparece incluso cuando los modelos cambian. Por tanto, *el hallazgo*

principal no es simplemente que existan diferencias entre grupos, sino que dichas diferencias son persistentes y resisten estrategias superficiales de corrección basadas únicamente en quitar atributos sensibles.

El estudio socioeconómico aporta el contexto necesario para interpretar esas brechas. Una parte importante de las variables que dominan la predicción del modelo está relacionada con renta, carga financiera, estructura del préstamo, *scoring* y territorio. Estas dimensiones son muy útiles desde el punto de vista estadístico, pero no pueden entenderse como neutrales en un problema como el crédito. En la práctica, condensan desigualdades previas en acceso a ingresos, patrimonio, estabilidad laboral, condiciones de vivienda y localización geográfica.

Este punto permite formular la interpretación central del trabajo. El modelo no necesita utilizar de forma explícita la raza o la etnia para producir resultados desiguales entre grupos, porque muchas variables que sí utiliza reflejan diferencias históricas y estructurales entre esos mismos grupos. Cuando el algoritmo aprende que ciertos perfiles financieros o territoriales tienen menor probabilidad de concesión, también puede estar aprendiendo, de forma indirecta, patrones de desigualdad que recaen con mayor intensidad sobre determinados colectivos. Así, el sesgo que emerge del análisis no debe entenderse principalmente como una discriminación directa programada en el modelo, sino como una reproducción algorítmica de desigualdades ya incorporadas en los datos.

La incorporación de una red neuronal perceptrón multicapa permitió comprobar si la conclusión del TFM se mantenía al introducir una arquitectura más flexible y no lineal. La respuesta fue afirmativa. La red neuronal tiene un rendimiento predictivo elevado, con una buena estabilidad entre muestras y una gran capacidad para generar puntuaciones probabilísticas informativas. En comparación con modelos lineales y gracias al ser una red neuronal multicapa es capaz de capturar relaciones no lineales entre variables financieras, geográficas y demográficas, lo que lo convierte en un benchmark interesante dentro del proyecto. La arquitectura elegida, basada en tres capas ocultas y entrenamiento adaptativo, ha mostrado una capacidad predictiva elevada, con `ROC-AUC` de 0,9363 en test, `PR-AUC` de 0,9545 y un gap de generalización muy reducido. Al mismo tiempo el análisis por grupos sensibles ha evidenciado como otros modelos anteriores que no es completamente uniforme entre categorías sexo, raza y etnia. Aunque ya se ha explicado la razón de estas diferencias, es necesario incorporar una evaluación explicativa de estabilidad y equidad, que se muestra en el siguiente punto, con *SHAP (Shapley Additive explanations)*.

La principal aportación de SHAP consiste en el refuerzo de la interpretabilidad, sin renunciar a su capacidad predictiva. El análisis concluye en que la red no toma decisiones de manera aleatoria o impredecible, sino que se basa sobre todo en variables financieras de alto contenido económico (. Las variables:

`ratio\_deuda\_ingresos`, `sistema\_evaluacion\_1`, `codigo\_estado`, `importe\_prestamo`, `ratio\_prestamo\_valor` concentran el mayor peso explicativo global.) y en variables territoriales. Además, permite defender 3 ideas, en primer lugar, aporta robustez a la red neuronal ya que afirma que la red tiene un rendimiento elevado y estable. En segundo lugar, que dicho rendimiento puede explicarse de manera comprensible mediante SHAP. Y, en tercer lugar, que la explicabilidad agrega información muy útil para discutir posibles diferencias entre grupos sensibles, reforzando el enfoque de equidad del trabajo. En consecuencia, SHAP no solo cumple una función técnica de interpretación del modelo, sino que aporta un valor metodológico claro al proyecto: convierte una red neuronal de alto rendimiento en un sistema mucho más transparente, defendible y alineado con el objetivo central del trabajo, que es analizar la relación entre capacidad predictiva y posible sesgo en decisiones automatizadas de crédito.

Desde el punto de vista metodológico, esta capa de explicabilidad resulta fundamental para la defensa del trabajo. No solo demuestra que la red neuronal puede explicarse, sino que además enlaza la capacidad predictiva con el problema central del TFM. El valor de SHAP no consiste simplemente en mostrar qué variables importan más, sino en permitir sostener con mayor solidez que el problema no es un supuesto uso directo y opaco de las variables sensibles, sino la absorción de desigualdades estructurales a través de variables aparentemente neutrales.

4. Conclusiones

El proyecto surge de la idea de responder a la siguiente pregunta: ¿si existen sesgos en la concesión automatizada de crédito? Sin embargo, el recorrido realizado a lo largo del trabajo muestra que la respuesta no es tan sencilla y no se puede reducir en un sí o no sin matizar. Ya que cuando el sesgo aparece en este tipo de contextos, rara vez es de forma directa o se puede aislar fácilmente. Y precisamente por eso, la principal aportación del trabajo no reside en haber entrenado modelos predictivos con un buen rendimiento, sino en haber demostrado que la discusión sobre equidad algorítmica exige mirar más allá de la precisión global y atender al modo en que los datos, las variables y el contexto social terminan condicionando las decisiones del modelo. A medida que se avanzaba el análisis, fue quedando claro que la concesión de crédito no es un problema puramente técnico. El análisis exploratorio inicial (EDA), ya apuntaba a una realidad algo compleja, con un volumen elevado de datos, una fuerte heterogeneidad en las variables, con variables de factores económicos, territoriales y demográficos. La construcción del conjunto final (*df_model*), no fue, por tanto, una simple limpieza sino una decisión orientada a conservar variables con importancia que además fuesen pre-concesión, sin perder de vista el problema central del trabajo: estudiar hasta qué punto las decisiones automatizadas pueden reproducir desigualdades previas.

Los resultados predictivos obtenidos a lo largo del benchmark muestran que tanto los modelos lineales como los modelos de Machine Learning (*HistGradientBoosting*) y, finalmente la red neuronal (*perceptrón multicapa*), alcanzan niveles altos de discriminación y estabilidad. Esto asegura que existen patrones con la suficiente consistencia como para anticipar la probabilidad de concesión o denegación del crédito.

Sin embargo, esa misma fortaleza predictiva obliga a plantear una cuestión de fondo: si el modelo es bueno prediciendo, ¿qué es exactamente lo que está aprendiendo? Esta pregunta es importante, porque un algoritmo puede ser eficaz y a la vez, estar capturando regularidades que reflejan desigualdades históricas o estructurales.

En este sentido, una de las conclusiones más relevantes es que la simple eliminación de variables sensibles no resuelve el problema del sesgo. Los análisis realizados con regresión logística y con LASSO muestran que el rendimiento del modelo apenas cambia cuando se excluyen las variables sensibles. Lejos de interpretarse como una señal tranquilizadora, este resultado sugiere precisamente lo contrario: que el modelo es capaz de reconstruir parte de esa información por vías indirectas, utilizando variables que formalmente no son sensibles pero que están estrechamente vinculadas con la posición socioeconómica, el territorio, el contexto residencial o la estructura del préstamo. Dicho de otra manera, el trabajo apunta a la existencia de variables proxy.

Las métricas de fairness refuerzan esta idea, las brechas observadas no son uniformes para todos los atributos sensibles. El patrón más consistente del trabajo es que las mayores diferencias aparecen en raza y etnia, mientras que en sexo las disparidades son más moderadas.

Esto significa que el sesgo potencial del sistema no parece distribuirse de forma homogénea, sino que se concentra sobre todo en los ejes donde las desigualdades estructurales suelen ser más profundas. Además, la comparación entre modelos con y sin variables sensibles sugiere que incluirlas no mejora de manera clara la equidad del resultado y en algunos casos puede incluso acentuar pequeñas brechas. Por tanto, el trabajo no avala la idea de que el problema pueda resolverse simplemente incorporando o retirando variables sensibles.

El estudio socioeconómico ayuda a dar sentido a este hallazgo. Variables relacionadas con renta, carga financiera, scoring, localización o características del entorno no son neutrales desde un punto de vista social. Aunque en términos técnicos aparezcan como buenos predictores, también están insertas en contextos donde las oportunidades y las restricciones no se distribuyen de manera igual entre colectivos. En consecuencia, cuando el modelo aprende de estas variables, no solo está aprendiendo relaciones financieras, sino también una determinada fotografía de las desigualdades preexistentes en el acceso al crédito, al ingreso, al patrimonio o al territorio. Esta es, probablemente, la idea más importante que deja este trabajo de investigación: el sesgo no aparece

únicamente cuando el algoritmo utiliza de forma explícita una categoría sensible, sino también cuando aprende patrones que están socialmente estratificados.

La incorporación de la red neuronal y de SHAP, permitió reforzar aún más esta conclusión. La red neuronal confirmó que la presencia de diferencias entre grupos no era una peculiaridad de un único modelo, sino que se mantenía.

Por su parte, SHAP se utilizó con la idea de abrir esa “caja negra”, y mostrar que las variables con mayor peso eran, sobre todo, factores financieros y territoriales como: ratio deuda-ingresos, el sistema de evaluación, el importe del préstamo, la relación entre préstamo y valor del activo o el estado de residencia. Esta información es muy valiosa porque desplaza el foco: el problema no parece residir en un uso masivo y directo de sexo, raza o etnia como motores principales de predicción, sino en la capacidad del modelo para apoyarse en variables que condensan desigualdades estructurales y que, por ello, pueden generar resultados desiguales entre grupos.

La conclusión del trabajo es que, si existen indicios sólidos de sesgo en la concesión automatizada del crédito analizada, pero se trata de un sesgo predominantemente indirecto, estructural y mediado por variables proxy, más que de un sesgo simple y directo asociado exclusivamente a la presencia de atributos sensibles en el modelo.

Esta afirmación debe formularse con prudencia: el proyecto no demuestra por sí solo discriminación intencional ni permite establecer una causalidad jurídica concluyente. Lo que sí pone de manifiesto es que los modelos producen resultados diferenciales entre colectivos, que esas diferencias persisten cuando se eliminan variables sensibles y que, por tanto, la neutralidad aparente del sistema no basta para garantizar su equidad.

En definitiva, el trabajo permite sostener que el verdadero reto no es crear modelos precisos, sino comprender las desigualdades, ya que, en contextos como el presente, evaluar un algoritmo únicamente por su capacidad predictiva resulta ineficiente. Por ello, es necesario combinar rendimiento, fairness, contexto social y herramientas de explicabilidad.

Un modelo puede funcionar muy bien y, al mismo tiempo, seguir siendo problemático desde el punto de vista distributivo. Por ello, hablar de sesgos algorítmicos no es cuestionar solo al modelo, sino interrogar también la estructura de los datos y las desigualdades que estos reflejan.